

transformer

Yifei He

2026 年 7 月 6 日

首先提到翻译问题要求神经网络的输入维度和输出维度是任意的。首先让一个模型可以处理任意维度的输入，token 化。不同的信息之间肯定需要信息传递，但是单纯通过残差连接值矩阵模型就太简单了我们需要引入权重，权重应该和信息传递的输出和接受方有关同时应该是一个实数。于是我们想到 qk 矩阵点积构造权重为了让单个 token 内部传递信息只需要 mlp

不同 token 之间传递信息需要位置相关。所以需要引入位置编码。

该架构应该无法使用 fnn 表示

于是我们得到了一个输入任意维度输出为对应维度的 nn 我们事先指定小于输入维度个数的输出为我们需要的就得到了一个输入为任意维度输出为指定维度的 nn 很容易的该模型非常适合用于预测，通过自回归，滚动预测任意长度的值。如果我们让模型自己决定何时停止输出，这就是一个无输入，输出模型自己决定的维度的 nn 自然语言输出也类似于预测所以可以用这样的模型表示。

回到最初的问题，我们需要的模型是输入任意维度输出任意维度，所以我们还需要在上述模型的基础上添加一个输入。这就是 cross attention 部分。我们可以将翻译任务分为两部分，首先是理解原文，转化为一个表示其含义的向量，然后根据目标语言的语法知识来输出译文。我们之前提到的 decoder only transformer 就可以用于第二步且输出可以是任意维度。所以我们只需要类似 self attention 但将信息的发射端改为完全不同的 token 空间就可以实现任意维度信息的嵌入

参考文献